Machine Learning

Project : Explainable and Trustworthy AI

Hugo Da Cunha Carreira - Yacine Farhi - Hajar Izandaz

ET5 IIM

10 Mars 2025

Université Paris-Saclay, Polytech Paris-Saclay, Bâtiment 620, maison de l'ingénieur, 91400, Orsay

Lien github :
https://github.com/hajarizandazz/Explainable-and-Trustworthy-Model-

Sommaire

Sommaire **1**
Section 1 - Multi-choice questions **2**
A. What does local interpretability in Explainable Artificial Intelligence (XAI) refer to? 2
B. Which of the following best describes accountability in the context of Trustworthy AI? 2
Section 2 - Counterfactual Explanations for Understanding Model Predictions **3**
Section 3 - Explainable AI for healthcare systems **4**
Section 4 – Implementation of XAI Examples **5**
1. Chargement/ Affichage Dataset 5
2. Pré-Traitement Dataset 5
3. Choix du modèle 6
4. Évaluation du Modèle 8
5. Explication en utilisant LIME 9
6. Explication en utilisant SHAP 10
Installation des bibliothèques 12

Section 1 - Multi-choice questions

A. What does local interpretability in Explainable Artificial Intelligence (XAI) refer to?

A) Understanding the overall behavior of the model
B) Understanding individual predictions or decisions made by the model
C) Understanding the data preprocessing steps in the model
D) Understanding the training process of the model

L'intelligence artificielle explicable (XAI) cherche à rendre les décisions des algorithmes transparentes pour les humains. L'interprétabilité locale vise à se concentrer sur une seule prédiction spécifique. Ici, la réponse correcte est la “B” car on souhaite comprendre une décision individuelle de notre modèle. Ensuite, cela ne peut pas être la réponse “A” car la compréhension générale d’un modèle fait référence à son interprétabilité globale. La réponse “C”, n’est pas bonne non plus car la compréhension des étapes de data preprocessing intervient avant que notre modèle émette une décision. Enfin, ce n’est pas la réponse “D” car la compréhension du processus d'entraînement du modèle n’est pas liée à l'interprétabilité locale.

B. Which of the following best describes accountability in the context of Trustworthy AI?

A) The requirement that AI systems operate without any human oversight
B) The responsibility of the entities involved to ensure and answer for the outcomes produced by AI systems
C) The ability of AI systems to self-correct when errors occur
D) The focus on minimizing the cost of deploying AI systems

La notion d’obligation de rendre des comptes dans le contexte d’une IA de confiance est qu’un algorithme ne peut pas être tenu responsable de ses actes. En effet, derrière chaque IA nous avons un ou des concepteur(s) qui doivent se rendre responsables des résultats produits par les systèmes d'IA qu’ils ont créés. La bonne réponse est donc la réponse “B”.Cela ne peut pas être la réponse “A” car une IA sans supervision humaine est opposée aux AI de confiance.Ensuite, la réponse “C” n’est pas adéquate non plus car le fait qu’une IA doit s'autocorriger n’a rien à voir avec la responsabilité qu’elle doit avoir par rapport à la loi si le système est défaillant. Enfin la réponse “D”, n’est pas correcte non plus car la minimisation des coûts de déploiement est plus une notion liée aux objectifs financiers du modèle et non à la notion de confiance.

Section 2 - Counterfactual Explanations for Understanding Model Predictions

Les explications contrefactuelles permettent de montrer ce qui aurait pu être différent dans le résultat final si les données de départ étaient différentes. Cette explication est utile pour l'utilisateur car elle permet à celui- ci de ne pas seulement lui montrer pourquoi une décision à été prise mais montrer aussi les autres scénarios possibles si les données d'entrées étaient différentes. Elle permet aussi au concepteur de comprendre les seuils choisis par le modèle et savoir si oui ou non ils sont corrects.

Un exemple serait celui d'une IA utilisée dans le secteur bancaire afin de faire l'analyse de si oui ou non on accorde un prêt à un client en fonction des ses données de départ. Imaginons, le scénario ou le prêt bancaire est refusé par la banque. Sans explication contrefactuelles, notre modèle reverrait que le pourcentage de risque est trop élevé (exemple: > 90%) principalement à cause de l'âge du client et de ses revenus mensuels. Maintenant, si on ajoute l'explication contrefactuelle, notre modèle renverrait que le prêt à été refusé mais que si par exemple le client avait un apport plus important comme 10000 euros en plus et avait demandé un prêt qui s'étale sur 15 ans au lieu de 10 ans alors le prêt aurait été accepté.

Ici, notre explication contrefactuelle permet de donner au client le point de bascule pour que sa demande soit acceptée.

Section 3 - Explainable AI for healthcare systems

Les modèles black box tels que certains réseaux de neurones peuvent obtenir de très bonnes performances de prédiction mais leur fonctionnement est souvent difficile à comprendre. Dans le domaine médical, il est essentiel que les médecins puissent comprendre les raisons d'une prédiction avant de l'utiliser pour prendre une décision clinique.

Il existe plusieurs techniques d'Explainable AI (XAI) pour rendre un système compréhensible appelles XAI :

1. **Feature importance**

Les méthodes d'importance des variables permettent d'identifier les caractéristiques qui influencent le plus la prédiction du modèle. Dans un système de prédiction de maladie basé sur des données tabulaires, des variables comme le taux de glucose, l'indice de masse corporelle (BMI), la pression artérielle ou l'âge peuvent jouer un rôle important. Afficher ces informations aide les médecins à comprendre pourquoi le modèle considère qu'un patient présente un risque élevé.

2. **LIME (Local Interpretable Model-agnostic Explanations)**

La méthode LIME permet d'expliquer les prédictions individuelles en approximant localement le modèle complexe par un modèle plus simple et interprétable. La méthode modifie légèrement les données d'entrée autour d'un exemple donné et observe comment les prédictions changent. Cela permet de déterminer quelles variables ont influencé la prédiction pour un patient spécifique.

3. **SHAP (SHapley Additive exPlanations)**

Une autre technique largement utilisée est SHAP (SHapley Additive exPlanations). Les valeurs SHAP sont basées sur la théorie des jeux et mesurent la contribution de chaque variable à la prédiction finale du modèle. Elles permettent d'obtenir à la fois des explications locales (pour une prédiction spécifique) et globales (pour comprendre le comportement général du modèle). Par exemple, SHAP peut montrer qu'un niveau de glucose élevé augmente fortement la probabilité prédite de diabète.

Dans un contexte médical, ces méthodes d'explications sont les plus utiles. Ces approches améliorent la transparence du système d'intelligence artificielle, renforcent la confiance des médecins et permettent de vérifier si le raisonnement du modèle est cohérent avec les connaissances médicales avant d'utiliser ses prédictions.

Section 4 – Implementation of XAI Examples

1. Chargement/ Affichage Dataset

Dans cette première étape, le dataset est chargé afin de vérifier sa structure et son contenu avant d'appliquer les différentes étapes de pré-traitement.

```
=== Dataset shape ===
Rows: 768
Columns: 9

=== Column names ===
['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age', 'Outcome']

=== First 5 rows ===
   Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin   BMI  DiabetesPedigreeFunction  Age  Outcome
0            6      148             72             35        0  33.6                     0.627   50        1
1            1       85             66             29        0  26.6                     0.351   31        0
2            8      183             64              0        0  23.3                     0.672   32        1
3            1       89             66             23       94  28.1                     0.167   21        0
4            0      137             40             35      168  43.1                     2.288   33        1
```

Notre dataset contient **768 observations et 9 variables**, dont :

- **8 variables explicatives** (Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age)
- **1 variable cible : Outcome**, indiquant si le patient est diagnostiqué diabétique ou non.

L'affichage des premières lignes permet d'identifier certaines valeurs potentiellement incorrectes, comme des valeurs égales à 0 dans certaines colonnes médicales, ce qui sera traité dans la phase de pré-traitement.

2. Pré-Traitement Dataset

Avant l'entraînement des modèles, plusieurs étapes de pré-traitement des données sont appliquées afin d'améliorer la qualité du dataset et garantir un apprentissage correct. Les principales étapes sont les suivantes :

- **Remplacement de certaines valeurs invalides**
  - valeurs **0** impossibles/irréalistes remplacées par **NaN** dans certaines colonnes
- **Imputation par la médiane pour remplir les cases vides**
- **Séparation des données :**
  - **x :** variables explicatives
  - **y :** variable cible (Outcome)
- **Division du dataset :**
  - Donnees separees en train et test grâce a ***train_test_split***
  - Option stratify utilisée pour garder la même proportion des résultats
- **Standardisation des features avec *StandardScaler***

Pour pouvoir appliquer exactement le même pré-traitement sur de nouvelles données, les objets suivants sont sauvegardés :

- **imputer.pk1 :** objet ayant appris comment remplir les valeurs manquantes. Donc il serra utile si on veut traiter de nouvelles données.
- **scaler.pk1 :** objet ayant appris comment standardiser les variables.

```
=== Basic dataset info ===
Rows: 768
Columns: 9

Columns:
['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age', 'Outcome']

Missing values before cleaning:
Pregnancies                 0
Glucose                     0
BloodPressure               0
SkinThickness               0
Insulin                     0
BMI                         0
DiabetesPedigreeFunction    0
Age                         0
Outcome                     0
dtype: int64

Invalid zeros replaced with NaN:
Glucose: 5
BloodPressure: 35
SkinThickness: 227
Insulin: 374
BMI: 11

Missing values after cleaning:
Pregnancies                   0
Glucose                       5
BloodPressure                35
SkinThickness               227
Insulin                     374
BMI                          11
DiabetesPedigreeFunction      0
Age                           0
Outcome                       0
dtype: int64
```

```
=== Processed data info ===
X_train shape: (614, 8)
X_test shape: (154, 8)
y_train shape: (614,)
y_test shape: (154,)

Class distribution in y_train (%):
Outcome
0    65.15
1    34.85
Name: proportion, dtype: float64

Class distribution in y_test (%):
Outcome
0    64.94
1    35.06
Name: proportion, dtype: float64

Preprocessing completed successfully.
Processed files saved in: data\processed
```

3. Choix du modèle

Nous avons testé plusieurs modèles de classification afin de déterminer celui qui est le plus performant pour notre problème :

- **Logistic Regression** avec des données scaled (car il se base sur les distances donc il est plus sensibles à l'échelle).
- **Decision Tree** avec des données non scaled
- **Random** Forest avec des données non scaled
- **KNN** avec des données scaled

Pour la partie explicabilité, un seul modèle sera finalement retenu.

Afin de comparer les différents modèles, nous utilisons plusieurs métriques d'évaluation. La métrique principale retenue est le **F1-score**, car elle représente un compromis équilibré entre **la précision (précision)** et **le rappel (recall)**.

Cette métrique permet d'évaluer :

- la proportion de prédictions correctes
- la capacité du modèle à détecter les vrais cas positifs
- la quantité de faux positifs générés par le modèle

Étapes de la procédure :

a. Entraînement des modèles.
b. Calcul des métriques de performance pour chaque modèle.
c. Comparaison des résultats à l'aide du F1-score.
d. Decision du meilleur modèle (dans notre cas le **Decision Tree** obtient le score le plus grand) (il détecte les cas positives)
e. Sauvegarde le modèle dans le fichier : *models/decision_tree.pkl*

```
=== logistic_regression ===
accuracy: 0.7078
precision: 0.6000
recall: 0.5000
f1_score: 0.5455

=== decision_tree ===
accuracy: 0.7597
precision: 0.6393
recall: 0.7222
f1_score: 0.6783

=== random_forest ===
accuracy: 0.7273
precision: 0.6364
recall: 0.5185
f1_score: 0.5714

=== knn ===
accuracy: 0.7273
precision: 0.6250
recall: 0.5556
f1_score: 0.5882

=== Best model ===
Selected model: decision_tree
Saved at: models\decision_tree.pkl
```

4. Évaluation du Modèle

Après la phase de sélection, le modèle retenu (Decision Tree) est évalué plus en détail sur le jeu de données de test afin de mesurer sa performance sur des données jamais vues pendant l'entraînement.

1) Chargement du modèle (Decision Tree) le meilleur modèle
2) Chargement des données de test
3) Calcul des métriques de performance (accuracy, precision, recall, f1-score)
4) Affichage de la matrice de confusion qui permet d'analyser plus précisément les performances du modèle en comparant :

Enfin, les résultats de l'évaluation sont sauvegardés dans les dossiers *evaluation\metrics* et *evaluation\figures*

```
=== Best model evaluation ===
=== Best model evaluation ===
Model: decision_tree
Model: decision_tree
accuracy: 0.7597
accuracy: 0.7597
precision: 0.6393
recall: 0.7222
recall: 0.7222
f1_score: 0.6783

Evaluation files saved in:
evaluation\metrics
evaluation\figures
```

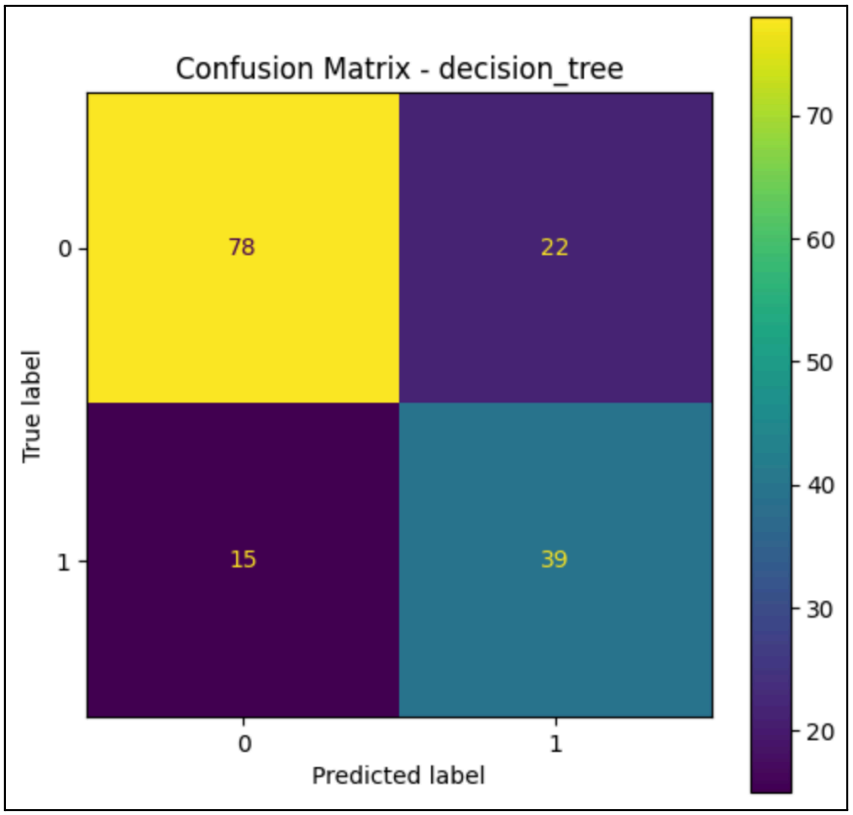

La matrice de confusion ci-dessus montre 78 vrais négatifs et 39 vrais positifs, ce qui indique une bonne capacité de classification globale. Le modèle produit toutefois 22 faux positifs et 15 faux négatifs, ce qui signifie qu'il reste quelques fausses alertes et certains cas de diabète non détectés.

5. Explication en utilisant LIME

Les étapes pour générer les explications LIME sont les suivantes :

- **Chargement du modèle sélectionné** (Decision Tree).
- **Sélection d'un ou deux patients** issus du jeu de test.
- **Génération des explications locales** avec la méthode **LIME**.
- **Sauvegarde des explications au format HTML** (affichage navigateur)

Résultats :

```
=== LIME explanations completed ===
Best model used: decision_tree
```

Les résultats suivants représentent des explications locales LIME pour deux patients précis:

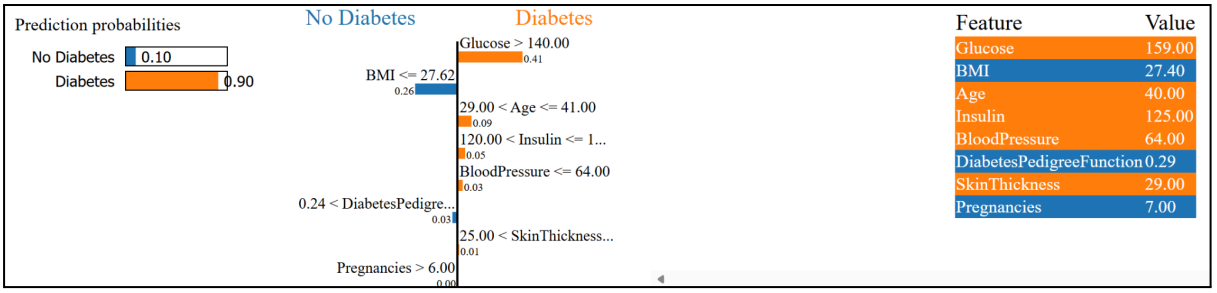

Ici, le modèle prédit Diabetes avec une probabilité de 0.90. La variable la plus influente est un taux de glucose très élevé (159), qui pousse fortement la prédiction vers la classe diabétique. D'autres facteurs comme l'âge, l'insuline et l'épaisseur cutanée contribuent aussi positivement à ce risque.

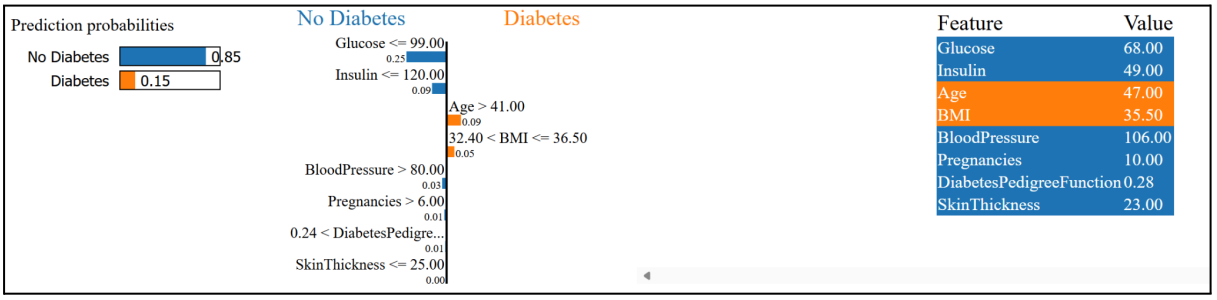

Dans ce second cas, le modèle prédit No Diabetes avec une probabilité de 0.85. Les principaux facteurs qui soutiennent cette décision sont un glucose faible (68) et une insuline modérée (49), qui orientent la prédiction vers la classe non diabétique. Malgré un âge plus élevé et un BMI modéré, ces variables ont un effet plus faible que le glucose.

Conclusion : Ces explications LIME montrent que le modèle prend des décisions différentes selon le profil du patient, et que le glucose apparaît comme l'une des variables les plus influentes dans les prédictions locales.

6. Explication en utilisant SHAP

Les étapes pour générer les explications SHAP sont les suivantes :

- **Chargement du modèle sélectionné** (Decision Tree).
- **Génération d'une explication globale**
- **Génération d'une ou deux explications locales**
- **Sauvegarde des figures générées**

Résultats :

```
=== SHAP explanations completed ===
Best model used: decision_tree
Files saved in: evaluation\figures
```

SHAP permet de comprendre comment chaque variable influence la prédiction d'un modèle. Elle est très utile car elle nous fournit à la fois des explications locales (pour un patient précis) et des explications globales (sur l'ensemble du dataset), ce qui aide à mieux interpréter et justifier les décisions du modèle.

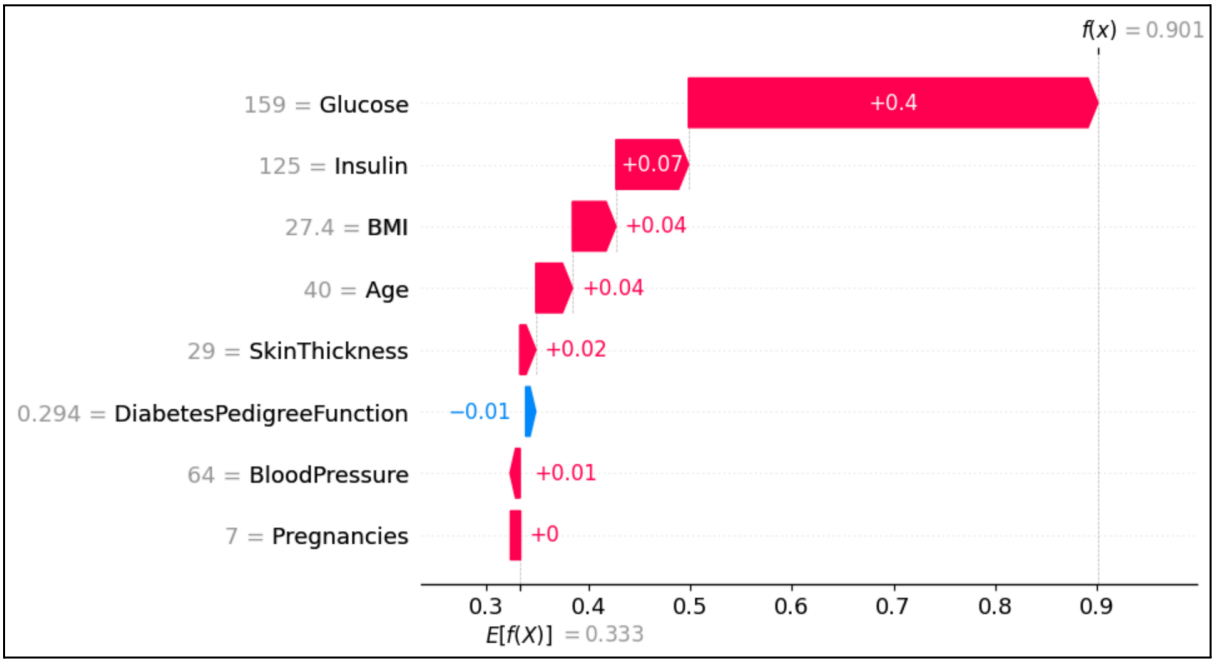

Ce graphique montre une explication locale pour un patient dont la probabilité prédite de diabète est très élevée (f(x) = 0,901). La variable la plus influente est le glucose élevé (159), qui augmente fortement la prédiction, suivie de l'insuline, du BMI et de l'âge. À l'inverse, la DiabetesPedigreeFunction réduit légèrement la prédiction, mais son effet reste faible.

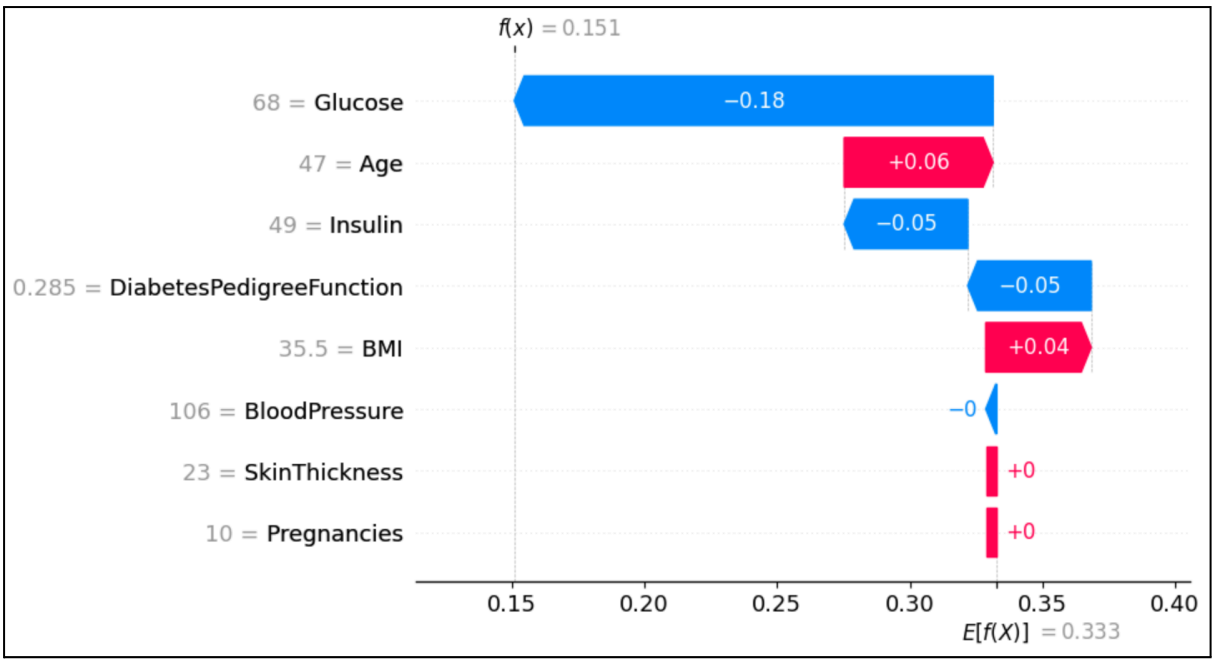

Ce second graphique explique une prédiction locale où la probabilité de diabète est faible (f(x) = 0,151). Le facteur principal qui fait baisser la prédiction est ici le glucose faible (68), complété par l'insuline et la DiabetesPedigreeFunction, qui contribuent aussi négativement. En revanche, l'âge et le BMI augmentent légèrement le risque, mais pas assez pour faire basculer la prédiction vers la classe diabétique.

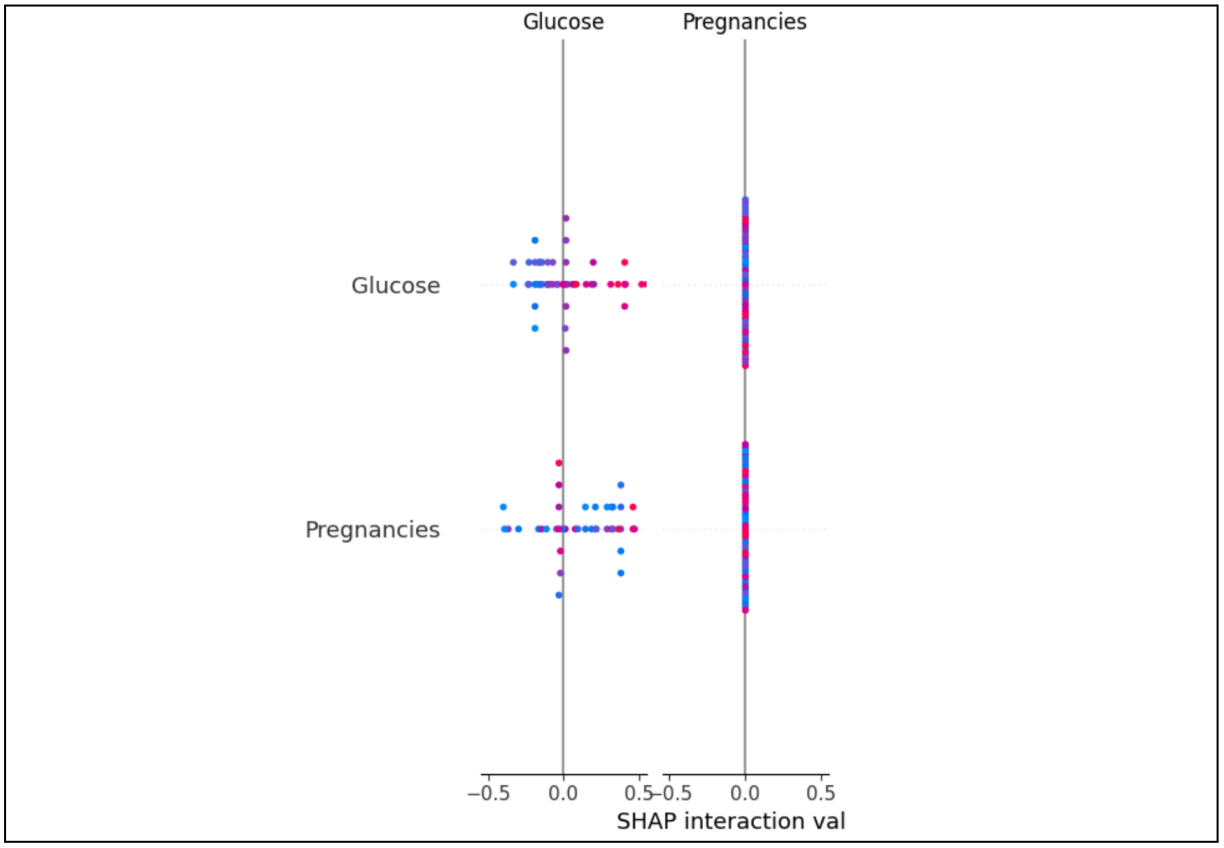

Ce graphique illustre les interactions entre variables, ici surtout entre Glucose et Pregnancies. On observe que le glucose a l'effet le plus visible sur les valeurs SHAP, ce qui

confirme qu'il s'agit d'une variable majeure dans les décisions du modèle. L'impact de Pregnancies apparaît plus faible et plus dispersé, ce qui suggère une influence moins forte et plus dépendante du contexte des autres variables.

Conclusion : Globalement, les résultats SHAP montrent que le **glucose** est la variable la plus déterminante dans les prédictions du modèle, aussi bien au niveau local que global, tandis que les autres variables jouent un rôle complémentaire selon le profil du patient.

Installation des bibliothèques

- **Commande 1 :** .\.venv\Scripts\python.exe -m pip install pandas
- **Commande 2 :** .\.venv\Scripts\python.exe -m pip install joblib
- **Commande 3 :** .\.venv\Scripts\python.exe -m pip install scikit-learn
- **Commande 4 :** .\.venv\Scripts\python.exe -m pip install lime shap matplotlib